

AULA 6 - INFERÊNCIA BAYESIANA

por Cibeles Russo

ICMC/USP - São Carlos SP

PROGRAMA

- O paradigma Bayesiano.
- Os diferentes tipos de prioris.
- Distribuições conjugadas.
- Estimativa Bayesiana.
- Densidade preditiva.
- Computação Bayesiana.
- Exemplos com PyMC3.

Referências e leituras recomendadas:

1. Migon, H. S., Gamerman, D. and Louzada, F. (2014). Statistical Inference: An Integrated Approach, Second Edition, CRC Press.
2. Caffo, B. (2016). Statistical Inference for Data Science. Leanpub. Disponível em <https://leanpub.com/LittleInferenceBook>
3. https://pt.wikipedia.org/wiki/Infer%C3%Aancia_bayesiana
4. Pacote PyMC <https://pypi.org/project/pymc/>

O PARADIGMA BAYESIANO

Seja uma amostra aleatória X_1, \dots, X_n que vem de um modelo $p(x|\theta)$, $\theta \in \Theta$ e sejam x_1, \dots, x_n os dados observados.

Sob o **paradigma clássico ou frequentista**, θ é um **parâmetro fixo e desconhecido**.

Sob o **paradigma Bayesiano**, consideramos modelos probabilísticos para **representar a incerteza** a respeito de θ .

Se temos informação **a priori** sobre o parâmetro θ , antes de observar os dados, por que não usá-la?

EXEMPLO:

Na aplicação de dados bancários que vimos na Aula 1, suponha que antes de observar os dados, exista um conhecimento prévio de que a proporção p de inadimplentes esteja em torno de 20%. Como incorporar esse conhecimento prévio? Uma possibilidade seria considerar uma distribuição a priori beta para a proporção p .

```
[1]: # Mais sobre a distribuição beta: https://pt.wikipedia.org/wiki/
↪ Distribuição_beta


import numpy as np
import matplotlib.pyplot as plt
from scipy import stats
from scipy.stats import beta

# Conjuntos de parâmetros da distribuição a priori para a proporção de
↪ inadimplentes
a_b_params = ((0.1, 0.1), (1, 1), (2, 8), (10, 5))
p = np.linspace(0, 1, 100)

# Plota as densidades da beta para cada conjunto de parâmetros
plt.figure(figsize=(15,4))
for i, (a, b) in enumerate(a_b_params):
    plt.subplot(1, len(a_b_params), i+1)

    prior = beta(a, b)

    plt.plot(p, prior.pdf(p))
    plt.xlabel(r'$p$')
    plt.title("a = {:.1f}, b = {:.1f}".format(a, b))
    plt.tight_layout()
```



TEOREMA DE BAYES

Ver, por exemplo: https://pt.wikipedia.org/wiki/Teorema_de_Bayes

Sejam

- $p(\theta)$ a **distribuição a priori** para θ .
- $l(\theta, x) = p(x|\theta)$ a **verossimilhança** de θ .
- $p(\theta|x)$ a **distribuição a posteriori** de θ .

O Teorema de Bayes ilustra o aumento de informação com a introdução do conhecimento a priori

$$p(\theta|x) = \frac{p(x, \theta)}{p(x)} = \frac{p(x|\theta)p(\theta)}{p(x)} = \frac{p(x|\theta)p(\theta)}{\int p(\theta, x)d\theta}.$$


Em outras palavras:

distribuição a posteriori \propto verossimilhança \times distribuição a priori

Para um valor fixo de x , as duas fontes de informação para θ são

- a função $l(\theta; x) = p(x|\theta)$ fornece a plausibilidade ou verossimilhança de cada um dos possíveis valores de θ e
- $p(\theta)$ é chamada distribuição a priori de θ ,

que, combinadas, levam à distribuição a posteriori de θ , $p(\theta|x)$.



Assim, a forma usual do teorema de Bayes é $p(\theta|x) \propto l(\theta; x)p(\theta)$.

O termo omitido $p(x)$ é apenas uma constante normalizadora e não depende de θ .



Para x fixo, a **verossimilhança** fornece a **plausibilidade** de cada um dos possíveis valores de θ .

Já a **distribuição a priori** $p(\theta)$ incorpora o **conhecimento do pesquisador**.

Essas duas quantidades combinadas são levadas à **distribuição a posteriori** de θ .

A **distribuição a posteriori** de θ dados x_1, \dots, x_n observados é dada por:

$$p(\theta|x_1, \dots, x_n) = \frac{p(x_1, \dots, x_n|\theta)p(\theta)}{\int_{\Theta} p(x_1, \dots, x_n|\theta)p(\theta)d\theta}$$

- $p(x_1, \dots, x_n|\theta) = \prod_{i=1}^n p(x_i|\theta) = L(\theta|x_1, \dots, x_n)$ é a **função de verossimilhança** de θ .

- O denominador

$$\int_{\Theta} p(x_1, \dots, x_n|\theta)p(\theta)d\theta = C(x_1, \dots, x_n).$$

É comum escrever que

$$p(\theta|x_1, \dots, x_n) = \frac{L(\theta|x_1, \dots, x_n)p(\theta)}{C(x_1, \dots, x_n)} \propto L(\theta|x_1, \dots, x_n)p(\theta),$$

DISTRIBUIÇÃO PREDITIVA

A constante normalizadora da posteriori pode ser facilmente recuperada pois $p(\theta|x) = kp(x|\theta)p(\theta)$ onde

$$k^{-1} = \int p(x|\theta)p(\theta)d\theta = E_{\theta}[p(X|\theta)] = p(x)$$

chamada **distribuição preditiva** (ou marginal) de X .

Esta é a distribuição esperada para a observação x dado θ . Assim,

- Antes de observar X podemos checar a adequação da priori fazendo previsões via $p(x)$.
- Se X observado recebia pouca probabilidade preditiva então o modelo deve ser questionado, revisado, ou existe observação aberrante.

Se, após observar $X = x$, estamos interessados na previsão de uma quantidade Y , também relacionada com θ , e descrita probabilisticamente por $p(y|\theta)$ então

$$p(y|x) = \int p(y, \theta|x)d\theta = \int p(y|\theta, x)p(\theta|x)d\theta$$

Os conceitos de priori e posteriori são relativos àquela observação que está sendo considerada no momento. Assim, $p(\theta|x)$ é a posteriori de θ em relação a X (que já foi observado) mas é a priori de θ em relação a Y (que não foi observado ainda).

Após observar $Y = y$ uma nova posteriori (relativa a $X = x$ e $Y = y$) é obtida aplicando-se novamente o teorema de Bayes.

Exemplo (Gamerman e Migon, 1993)



Um médico “desconfia” que um paciente pode ter uma doença. Baseado na sua experiência, no seu conhecimento sobre esta doença e nas informações dadas pelo paciente, **ele assume que a probabilidade do paciente ter a doença é 0.7**. A quantidade de interesse, desconhecida, é definida como

$$\theta = \begin{cases} 1, & \text{se o paciente tem a doença,} \\ 0, & \text{se o paciente não tem a doença.} \end{cases}$$

Para aumentar sua quantidade de informação sobre a doença o médico aplica um teste X relacionado com θ através da distribuição

$$P(X = 1|\theta = 0) = 0.40 \text{ e}$$

$$P(X = 1|\theta = 1) = 0.95$$

e o resultado do teste foi positivo (ou seja, observou-se $X = 1$).

É bem intuitivo que a probabilidade de doença deve ter aumentado após este resultado e a questão aqui é quantificar este aumento. Usando o teorema de Bayes, segue que

$$P(\theta = 1|X = 1) \propto l(\theta = 1; X = 1)p(\theta = 1) = (0.95)(0.7) = 0.665$$

$$P(\theta = 0|X = 1) \propto l(\theta = 0; X = 1)p(\theta = 0) = (0.40)(0.3) = 0.120.$$

A constante normalizadora é tal que $P(\theta = 0|X = 1) + P(\theta = 1|X = 1) = 1$, i.e.,

$$k(0.665) + k(0.120) = 1 \text{ e } k = 1/0.785.$$

Portanto, a distribuição a posteriori de θ é

$$P(\theta = 1|X = 1) = 0.665/0.785 = 0.847$$

$$P(\theta = 0|X = 1) = 0.120/0.785 = 0.153.$$

O aumento na probabilidade de doença não foi muito grande porque a verossimilhança $l(\theta = 0; X = 1)$ também era grande (o modelo atribuía uma plausibilidade grande para $\theta = 0$ mesmo quando $X = 1$).

Agora o médico aplica outro teste Y cujo resultado está relacionado a θ através da seguinte distribuição

$$P(Y = 1|\theta = 0) = 0.04 \text{ e}$$

$$P(Y = 1|\theta = 1) = 0.99.$$

Mas antes de observar o resultado deste teste é interessante obter sua distribuição preditiva.

Como θ é uma quantidade discreta segue que

$$p(y|x) = \sum_{\theta} p(y|\theta)p(\theta|x)$$

e note que $p(\theta|x)$ é a priori em relação a Y .

Assim,

$$P(Y = 1|X = 1) = P(Y = 1|\theta = 0)P(\theta = 0|X = 1) + P(Y = 1|\theta = 1)P(\theta = 1|X = 1)$$

$$= (0.04)(0.153) + (0.99)(0.847) = 0.845$$

$$P(Y = 0|X = 1) = 1 - P(Y = 1|X = 1) = 0.155.$$



O resultado deste teste foi negativo ($Y = 0$).

Neste caso, é também intuitivo que a probabilidade de doença deve ter diminuído e esta redução será quantificada por uma nova aplicação do teorema de Bayes,

$$P(\theta = 1|X = 1, Y = 0) \propto l(\theta = 1; Y = 0)P(\theta = 1|X = 1) \propto (0.01)(0.847) = 0.0085$$

$$P(\theta = 0|X = 1, Y = 0) \propto l(\theta = 0; Y = 0)P(\theta = 0|X = 1) \propto (0.96)(0.153) = 0.1469.$$

A constante normalizadora é $1/(0.0085 + 0.1469) = 1/0.1554$ e assim a distribuição a posteriori de θ é

$$P(\theta = 1|X = 1, Y = 0) = 0.0085/0.1554 = 0.055$$

$$P(\theta = 0|X = 1, Y = 0) = 0.1469/0.1554 = 0.945.$$

Verifique como a probabilidade de doença se alterou ao longo do experimento

$$P(\theta = 1) = \begin{cases} 0.7 & \text{antes dos testes} \\ 0.847 & \text{após o teste X} \\ 0.055 & \text{após X e Y} \end{cases}$$

Note também que o valor observado de Y recebia pouca probabilidade preditiva. Isto pode levar o médico a repensar o modelo, i.e.,

- (i) Será que $P(\theta = 1) = 0.7$ é uma priori adequada?
- (ii) Será que as distribuições amostrais de X e Y estão corretas? O teste X é tão inexpressivo e Y é realmente tão poderoso?

OS DIFERENTES TIPOS DE PRIORIS

Destacamos as distribuições a priori

- **Priori não-informativa**
 - Uniforme
 - Priori vaga (às vezes imprópria)
- **Priori informativa**
 - Conhecimento do pesquisador dá informação sobre os parâmetros
- **Priori conjugada**
 - Priori e posteriori tem a mesma distribuição, a menos dos parâmetros (em geral facilita os cálculos)

DISTRIBUIÇÕES CONJUGADAS

Leituras recomendadas:

- Notas Ricardo Ehlers e Paulo Justiniano: <http://www.leg.ufpr.br/~paulojus/CE227/ce227/node1.html>
- Conjugate Prior Explained, with examples & proofs: <https://towardsdatascience.com/conjugate-prior-explained-75957dc80bfb>



Vantagem de usar distribuições a priori conjugadas: principalmente **ganho de custo computacional**.

	Priori	Núcleo da Verossimilhança	Posteriori
θ proporção	Beta	Bernoulli	Beta
θ média	Normal	Normal	Normal
taxa de falha	Gama	Poisson	Gama
	Dirichlet	Multinomial	Dirichlet

EXEMPLO DE PRIORI CONJUGADA BETA-BERNOULLI

Ver <https://towardsdatascience.com/conjugate-prior-explained-75957dc80bfb>

No exemplo do banco, se considerarmos que

- $X = \begin{cases} 1, & \text{se o cliente é classificado como inadimplente,} \\ 0, & \text{caso contrário.} \end{cases}$
- $X \sim \text{Bernoulli}(p)$
- Verossimilhança:

Para n suficientemente grande, pelo TLC sabemos que a distribuição amostral de \bar{X} se aproxima da normal (será usada para graficar a verossimilhança)

$$\bar{X} \sim N\left(p, \frac{p(1-p)}{n}\right).$$

Além disso, $Y = \sum_{i=1}^n X_i \sim \text{binomial}(n, p)$.

- Priori: $p \sim \text{beta}(2, 8)$
- Posteriori: $p|k \sim \text{beta}(k + a, n - k + b)$

onde k é o número de sucessos observados na amostra.

```
[2]: import pandas as pd

# Indique o seu diretório se necessário
#pkgdir = '/hdd/MBA/ECD/Data'
#dados = pd.read_csv(f'{pkgdir}/dados_banco.csv', index_col=0)

# Dados banco - Leitura dos dados
dados = pd.read_csv('https://raw.githubusercontent.com/cibelerusso/
↳Estatistica-Ciencia-Dados/main/Data/dados_banco.csv', index_col=0)

dados.head()
```

```
[2]:      Sexo  Idade  Empresa  Salario  Saldo_cc  Saldo_poupança  \
Cliente
75928     M     32   Privada   5719.00    933.79             0.0
```



52921	F	28	Privada	5064.00	628.37	0.0
8387	F	24	Autônomo	4739.00	889.18	0.0
54522	M	30	Pública	5215.00	1141.47	0.0
45397	M	30	Autônomo	5215.56	520.70	0.0

	Saldo_investimento	Devedor_cartao	Inadimplente
Cliente			
75928	0.0	6023.68	0
52921	0.0	1578.24	0
8387	0.0	2578.70	0
54522	0.0	4348.96	0
45397	0.0	1516.78	1

```
[3]: # Vamos trabalhar com uma amostra

import random

a = 10
b = 5

amostra = dados.sample(n=100, replace=False, random_state=10)

n = len(amostra)
k = amostra['Inadimplente'].sum()
posteriori = beta(a + k, n - k + b)

k/n
```

[3]: 0.23

```
[4]: from scipy.stats import norm

# Eixo x entre 0 e 1 de .002 em .002.
x_axis = np.arange(0, 1, 0.002)

# Plota as densidades da beta para cada conjunto de parâmetros
plt.figure(figsize=(20,6))

prior = beta(a, b)

p_chapeu = amostra['Inadimplente'].mean()
dp = np.sqrt(p_chapeu*(1-p_chapeu)/n)
```




```


media = p_chapeu
dp = np.sqrt(media*(1-media)/n)

plt.s = 0
plt.rcParams.update({'font.size': 22})

plt.plot(x_axis, norm.pdf(x_axis, media, dp), label='verossimilhança')
plt.plot(x_axis, prior.pdf(x_axis), label='priori')
plt.plot(x_axis, posteriori.pdf(x_axis), label='posteriori')
plt.xlabel(r'$p$')
plt.legend()

```

[4]: <matplotlib.legend.Legend at 0x7d990dd4f2e0>



[5]: *# Estimador bayesiano EAP (Esperança a posteriori)*

```
print('Média: %.2f' % posteriori.mean())
```

E para calcular um intervalo de credibilidade, decidimos uma probabilidade

Por exemplo 95% para a credibilidade

Uma maneira seria definir que 2,5% de cada cauda como os limites do intervalo
↪ (chamado intervalo simétrico)

Este método é válido quando a posteriori se aproxima de uma distribuição
↪ simétrica, pois nesse caso tende a gerar o intervalo com menor amplitude

A seguir, apresentamos outra solução com um intervalo de credibilidade de menor
↪ amplitude.

```
LI = posteriori.ppf(.025)
```

```
LS = posteriori.ppf(.975)
```

```
print("Intervalo com 95% de credibilidade: ({:.3f}, {:.3f})".format(LI,LS))
```

Média: 0.29



Intervalo com 95% de credibilidade: (0.208, 0.373)

ESTIMAÇÃO BAYESIANA

Leituras recomendadas:

- Notas Ricardo Ehlers e Paulo Justiniano: <http://www.leg.ufpr.br/~paulojus/CE227/ce227/node1.html>
- Migon, H. S., Gamerman, D. and Louzada, F. (2014). Statistical Inference: An Integrated Approach, Second Edition, CRC Press.

INTRODUÇÃO À TEORIA DA DECISÃO

Um problema de decisão fica completamente especificado pela descrição dos seguintes espaços:

- (i) Espaço do parâmetro ou estados da natureza, Θ .
- (ii) Espaço dos resultados possíveis de um experimento, Ω .
- (iii) Espaço de possíveis ações, A .

Uma regra de decisão δ é uma função definida em Ω que assume valores em A , i.e. $\delta : \Omega \rightarrow A$. A cada decisão δ e a cada possível valor do parâmetro θ podemos associar uma **perda** $L(\delta, \theta)$ assumindo valores positivos. Definimos assim uma **função de perda**.

Definição: O risco de uma regra de decisão, denotado por $R(\delta)$, é a **perda esperada a posteriori**, i.e.

$$R(\delta) = E_{\theta|\mathbf{x}}[L(\delta, \theta)].$$

Uma regra de decisão δ^* é **ótima** se tem risco mínimo, i.e. $R(\delta^*) < R(\delta)$, $\forall \delta$. Esta regra será denominada **regra de Bayes** e seu risco, **risco de Bayes**.

Exemplo:

Um laboratório farmacêutico deve decidir pelo lançamento ou não de uma nova droga no mercado. O laboratório só lançará a droga se achar que ela é eficiente mas isto é exatamente o que é desconhecido.

Podemos associar um parâmetro θ aos estados da natureza:

- droga é eficiente ($\theta = 1$),
- droga não é eficiente ($\theta = 0$)

e as possíveis ações como

- lança a droga ($\delta = 1$),
- não lança a droga ($\delta = 0$).

Suponha que foi possível construir a seguinte tabela de perdas levando em conta a eficiência da droga,



	eficiente ($\theta = 1$)	não eficiente ($\theta = 0$)
lança ($\delta = 1$)	-500	600
não lança ($\delta = 0$)	1500	100

Vale notar que estas perdas traduzem uma **avaliação subjetiva** em relação à gravidade dos erros cometidos.

Suponha agora que a incerteza sobre os estados da natureza é descrita por

$$P(\theta = 1) = \pi, 0 < \pi < 1$$

avaliada na distribuição atualizada de θ (seja a priori ou a posteriori).

Note que, para δ fixo, $L(\delta, \theta)$ é uma variável aleatória discreta assumindo apenas dois valores com probabilidades π e $1 - \pi$.

Assim, usando a definição de risco obtemos que

$$R(\delta = 0) = E(L(0, \theta)) = \pi 1500 + (1 - \pi) 100 = 1400\pi + 100$$

$$R(\delta = 1) = E(L(1, \theta)) = \pi(-500) + (1 - \pi) 600 = -1100\pi + 600$$

Uma questão que se coloca aqui é, para que valores de π a regra de Bayes será de lançar a droga.

Não é difícil verificar que as duas ações levarão ao mesmo risco, i.e.

$$R(\delta = 0) = R(\delta = 1) \text{ se somente se } \pi = 0.20.$$

Além disso, para $\pi < 0.20$ temos que $R(\delta = 0) < R(\delta = 1)$ e a regra de Bayes consiste em **não lançar a droga** enquanto que $\pi > 0.20$ implica em $R(\delta = 0) > R(\delta = 1)$ e a regra de Bayes deve ser de **lançar a droga**.

ESTIMADORES DE BAYES

Considere uma amostra aleatória X_1, \dots, X_n , tomada de uma distribuição com função de (densidade) de probabilidade $p(x|\theta)$, onde o valor do parâmetro θ é desconhecido.

Em um problema de inferência como este o valor de θ deve ser estimado a partir dos valores observados na amostra.

Se $\theta \in \Theta$ então é razoável que os possíveis valores de um estimador $\hat{\theta}(\mathbf{x})$ também devam pertencer ao espaço Θ .

Além disso, um bom estimador é aquele para o qual, com alta probabilidade, apresenta o seguinte erro

$$\hat{\theta}(\mathbf{x}) - \theta$$

próximo de zero.



FUNÇÕES DE PERDA

Para cada possível valor de θ e cada possível estimativa $a \in \Theta$ vamos associar **uma perda** $L(a, \theta)$ de modo que quanto maior a distância entre a e θ maior o valor da perda. A perda esperada a posteriori é dada por

$$E[L(a, \theta) | \mathbf{x}] = \int L(a, \theta) p(\theta | \mathbf{x}) d\theta$$

O **estimador de Bayes** será aquele que minimiza a perda esperada.

Função de perda quadrática

$$L(a, \theta) = (a - \theta)^2$$

O estimador de Bayes para θ será a **média de sua distribuição atualizada** (EAP: expected a posteriori).

Função de perda absoluta (introduz punições que crescem linearmente com o erro de estimação)

$$L(a, \theta) = |a - \theta|$$

O estimador de Bayes para θ é a **mediana de sua distribuição atualizada**.

Função de perda 0-1 (associam uma perda fixa a um erro cometido, não importando sua magnitude)

$$L(a, \theta) = \begin{cases} 1 & \text{se } |a - \theta| > \epsilon \\ 0 & \text{se } |a - \theta| < \epsilon \end{cases}$$

para todo $\epsilon > 0$.

Neste caso, o estimador de Bayes é a **moda da distribuição atualizada de θ** (MAP: maximum a posteriori).

A moda da posteriori de θ também é chamado de estimador de máxima verossimilhança generalizado (EMVG) e é o mais fácil de ser obtido dentre os estimadores vistos até agora.

Exemplo:

Suponha que queremos estimar a proporção θ de itens defeituosos em um grande lote. Para isto será tomada uma amostra aleatória X_1, \dots, X_n de uma distribuição de Bernoulli com parâmetro θ . Usando uma priori conjugada beta(a, b), após observar a amostra a distribuição a posteriori é beta($a+k, b+n-k$) onde $k = \sum_{i=1}^n x_i$.

A média desta distribuição beta é dada por $(a+k)/(a+b+n)$ e portanto o estimador de Bayes de θ usando perda quadrática é

$$\delta(\mathbf{x}) = \frac{a + \sum_{i=1}^n X_i}{a + b + n}.$$



ESTIMAÇÃO POR INTERVALOS

Pode-se desenvolver a estimação por intervalos por meio do **intervalo de credibilidade (ou intervalo de confiança Bayesiano)** baseado na distribuição a posteriori.

Definição:

C é um **intervalo de credibilidade** de $100(1-\alpha)\%$, ou nível de credibilidade (ou confiança) $1 - \alpha$, para θ se $P(\theta \in C) \geq 1 - \alpha$.

Obs: Quanto menor for o tamanho do intervalo, mais concentrada é a distribuição do parâmetro, ou seja o tamanho do intervalo informa sobre a dispersão de θ .

O **intervalo com o menor comprimento possível** é obtido tomando-se os valores de θ com maior densidade a posteriori, e esta idéia é expressa matematicamente na definição abaixo.

Definição:

Um intervalo de credibilidade C de $100(1-\alpha)\%$ para θ é de **máxima densidade a posteriori (MDP)** se $C = \{\theta \in \Theta : p(\theta|\mathbf{x}) \geq k(\alpha)\}$ onde $k(\alpha)$ é a maior constante tal que $P(\theta \in C) \geq 1 - \alpha$.

Usando esta definição, todos os pontos dentro do intervalo MDP terão densidade maior do que qualquer ponto fora do intervalo.

Um problema com os intervalos MDP é que eles não são invariantes a transformações 1 a 1, a não ser para transformações lineares. O mesmo problema ocorre com intervalos de comprimento mínimo na inferência clássica.

COMPUTAÇÃO BAYESIANA

Leituras recomendadas:

- Métodos de Monte Carlo: https://pt.wikipedia.org/wiki/M%C3%A9todo_de_Monte_Carlo
- Notas Ricardo Ehlers e Paulo Justiniano: <http://www.leg.ufpr.br/~paulojus/CE227/ce227/node1.html>
- Salvatier, John; Wiecki, Thomas V.; Fonnesbeck, Christopher. Probabilistic programming in Python using PyMC3. PeerJ Computer Science, v. 2, p.e55, 2016. Disponível em <https://peerj.com/articles/cs-55/>. Acesso em 15/05/2024.

A obtenção de informações a partir da distribuição a posteriori dos parâmetros pode envolver a avaliação de probabilidades ou esperanças, que exigem métodos computacionais baseados em simulações, como

- Método de Monte Carlo simples
- Monte Carlo com função de importância,
- Algoritmo de Metropolis-Hastings,
- Amostrador de Gibbs,



- Método do Bootstrap Bayesiano,
- Monte Carlo via cadeias de Markov (MCMC),
- Monte Carlo Hamiltoniano (HMC),
- No-U-Turn Sampler (NUTS).

HMC e NUTS aproveitam as informações de gradiente da probabilidade e alcançam uma convergência muito mais rápida do que os métodos de amostragem tradicionais, especialmente para modelos mais complexos.

O pacote PyMC3 do Python usa a programação probabilística para executar os métodos de HMC como o NUTS. Esse tipo de programação permite a especificação flexível e ajuste de modelos estatísticos bayesianos com sintaxe intuitiva e legível, embora poderosa, que é próxima da sintaxe natural que os estatísticos usam para descrever modelos.

EXEMPLOS

```
[6]: !pip install theano
      !pip install arviz==0.15.1
```

EXEMPLO BETA-BERNOULLI: CLIENTES DO BANCO

```
[9]: with pm.Model() as model:
      p = pm.Beta("p", 2, 8) #priori
      obs = pm.distributions.discrete.Bernoulli("obs", p,
      ↪observed=amostra['Inadimplente'])

      idata = pm.sample(2000, tune=1500, return_inferencedata=True)
```

<IPython.core.display.HTML object>

<IPython.core.display.HTML object>

<IPython.core.display.HTML object>

<IPython.core.display.HTML object>


```
[10]: az.summary(idata)
```

```
[10]:      mean      sd  hdi_3%  hdi_97%  mcse_mean  mcse_sd  ess_bulk  ess_tail  \
p  0.227  0.039   0.155   0.302     0.001    0.001   1737.0   2710.0


      r_hat
p      1.0
```



```
[11]: az.plot_posterior(idata);
```



```
[12]: az.plot_forest(idata, r_hat=True);
```



EXEMPLO: NORMAL COM DADOS SIMULADOS

Fonte: https://docs.pymc.io/pymc-examples/examples/pymc3_howto/api_quickstart.html

```
[13]: with pm.Model() as model:
      mu = pm.Normal("mu", mu=0, sigma=1) # priori
      obs = pm.Normal("obs", mu=mu, sigma=1, observed=np.random.randn(100)) # verossimilhança
```

```
[14]: model.basic_RVs
```

```
[14]: [mu, obs]
```

```
[15]: model.free_RVs
```

```
[15]: [mu]
```

```
[16]: model.observed_RVs
```

```
[16]: [obs]
```

VARIÁVEIS ALEATÓRIAS NÃO OBSERVÁVEIS

```
[17]: with pm.Model():
      x = pm.Normal("x", mu=0, sigma=1)
```

VARIÁVEIS ALEATÓRIAS OBSERVÁVEIS

```
[18]: with pm.Model():
      obs = pm.Normal("x", mu=0, sigma=1, observed=np.random.randn(100))
```

INFERÊNCIA

AMOSTRAGEM

```
[19]: with pm.Model() as model:
      mu = pm.Normal("mu", mu=0, sigma=1)
      obs = pm.Normal("obs", mu=mu, sigma=1, observed=np.random.randn(100))

      idata = pm.sample(2000, tune=1500, return_inferencedata=True)
```

<IPython.core.display.HTML object>

<IPython.core.display.HTML object>

<IPython.core.display.HTML object>



<IPython.core.display.HTML object>

```
[20]: idata.posterior.dims
```

```
[20]: Frozen({'chain': 2, 'draw': 2000})
```

AMOSTRAGEM COM 6 CADEIAS EM PARALELO

```
[21]: with pm.Model() as model:
      mu = pm.Normal("mu", mu=0, sigma=1)
      obs = pm.Normal("obs", mu=mu, sigma=1, observed=np.random.randn(100))

      idata = pm.sample(cores=4, chains=6, return_inferencedata=True)
```

<IPython.core.display.HTML object>

<IPython.core.display.HTML object>

```
[22]: idata.posterior["mu"].shape
```

```
[22]: (6, 1000)
```

PODEMOS INCLUIR PASSOS COM OUTROS MÉTODOS

```
[23]: with pm.Model() as model:
      mu = pm.Normal("mu", mu=0, sigma=1)
      obs = pm.Normal("obs", mu=mu, sigma=1, observed=np.random.randn(100))

      step = pm.Metropolis()
      trace = pm.sample(1000, step=step)
```

<IPython.core.display.HTML object>

<IPython.core.display.HTML object>

<IPython.core.display.HTML object>

<IPython.core.display.HTML object>

```
[24]: with pm.Model() as model:
      mu = pm.Normal("mu", mu=0, sigma=1)
      sd = pm.HalfNormal("sd", sigma=1)
      obs = pm.Normal("obs", mu=mu, sigma=sd, observed=np.random.randn(100))
      ↪ #verossimilhança

      step1 = pm.Metropolis(vars=[mu])
```



```

step2 = pm.Slice(vars=[sd])
idata = pm.sample(10000, step=[step1, step2], cores=4,
↪return_inferencedata=True)


```

<IPython.core.display.HTML object>

<IPython.core.display.HTML object>

ANÁLISE DE RESULTADOS

```
[25]: az.plot_trace(idata);
```



ESTATÍSTICA DE GELMAN-RUBIN (R CHAPÉU)

```
[26]: az.summary(idata)
```

```
[26]:
```

	mean	sd	hdi_3%	hdi_97%	mcse_mean	mcse_sd	ess_bulk	ess_tail	\
mu	0.046	0.106	-0.146	0.250	0.001	0.001	5906.0	6753.0	
sd	1.063	0.075	0.924	1.205	0.000	0.000	38451.0	29012.0	


```


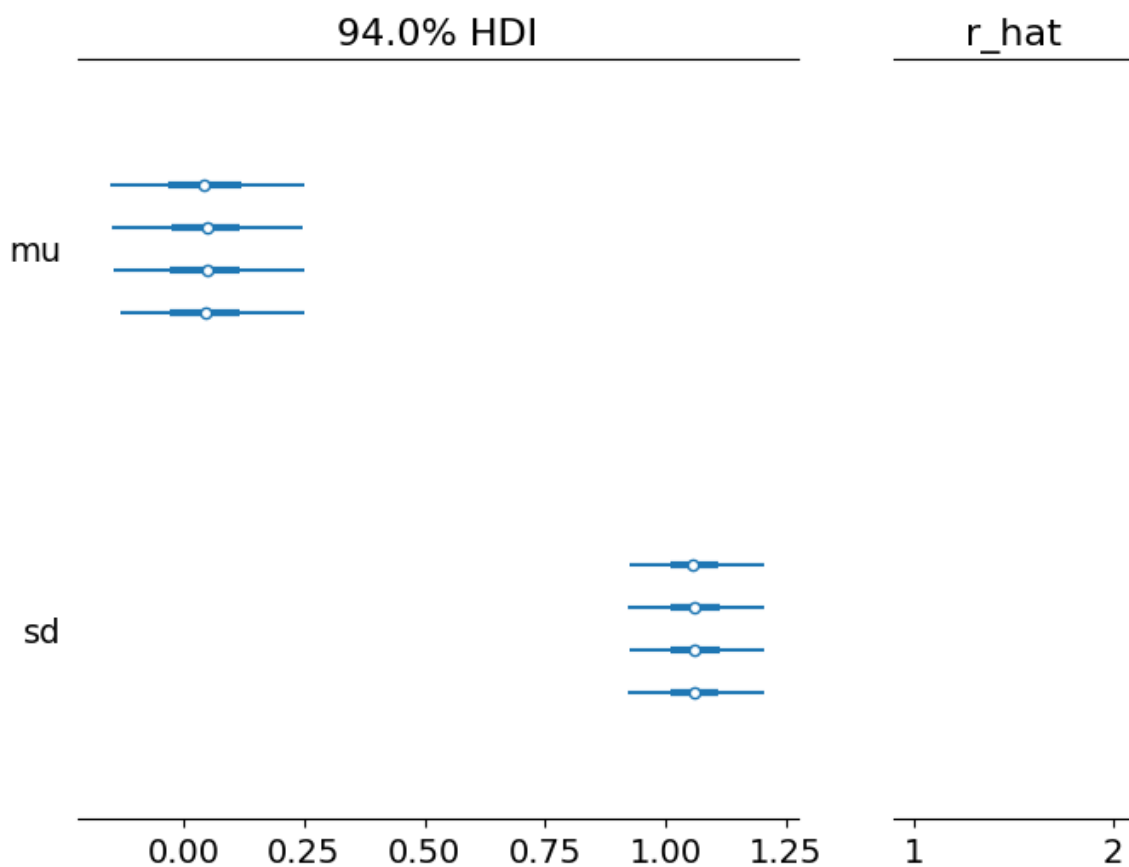
r_hat
mu    1.0
sd    1.0

```

```
[27]: az.plot_forest(idata, r_hat=True);
```


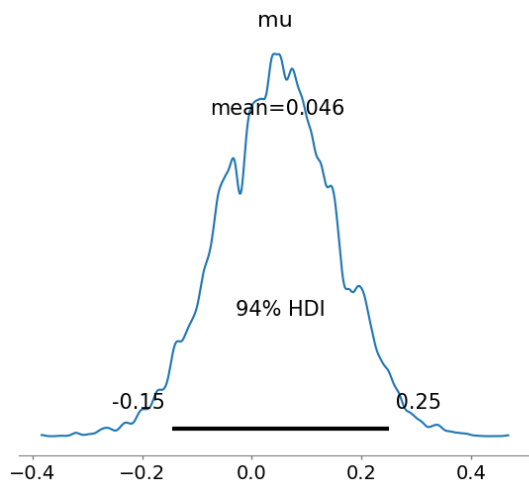
```
az.plot_posterior(idata);
```





```
[28]: az.plot_posterior(idata);
```





[28] :

