Introdução a Ciências de Dados

Introdução

Francisco A. Rodrigues
ICMC/USP
francisco@icmc.usp.br

Aula 1: Introdução

- O que é Ciência de Dados
- Problemas e Soluções em Ciência de Dados

O que é Ciência de Dados

"Ciência de dados (em inglês: data science) é uma área interdisciplinar voltada para o estudo e a análise de dados, estruturados ou não, que visa a extração de conhecimento ou insights para possíveis tomadas de decisão, de maneira similar à mineração de dados."

WIKIPÉDIA
A enciclopédia livre

O que é Ciência de Dados

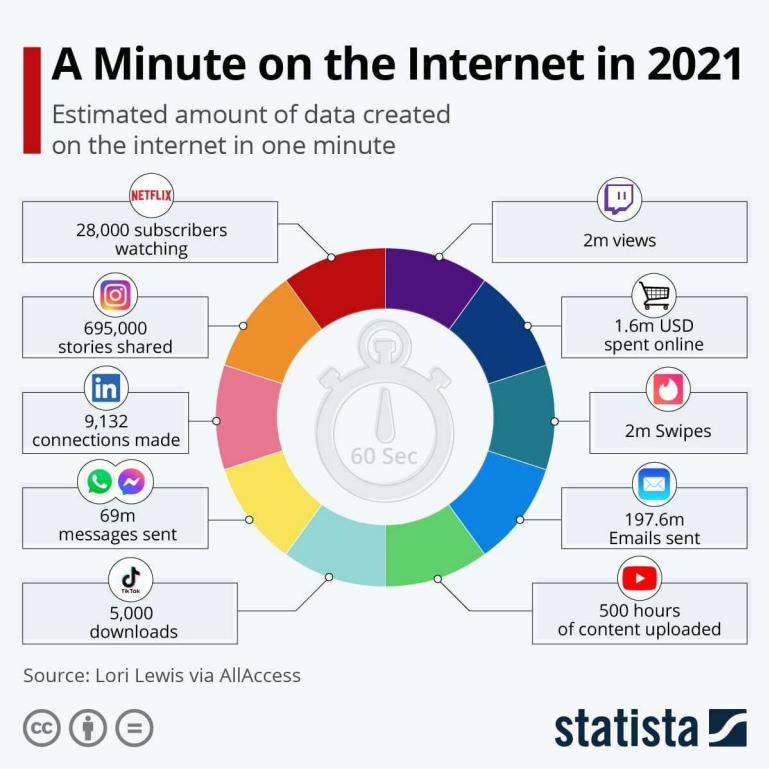

O que é Ciência de Dados

O que é Ciência de Dados

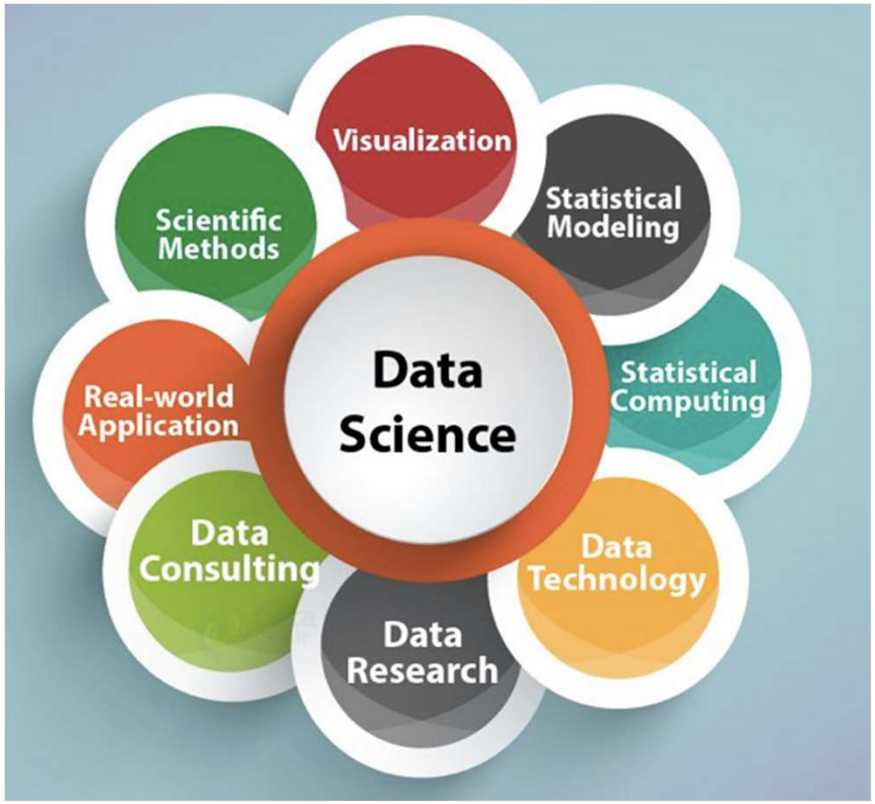

Ciência de Dados

=

Ciência

+

Dados

Método científico

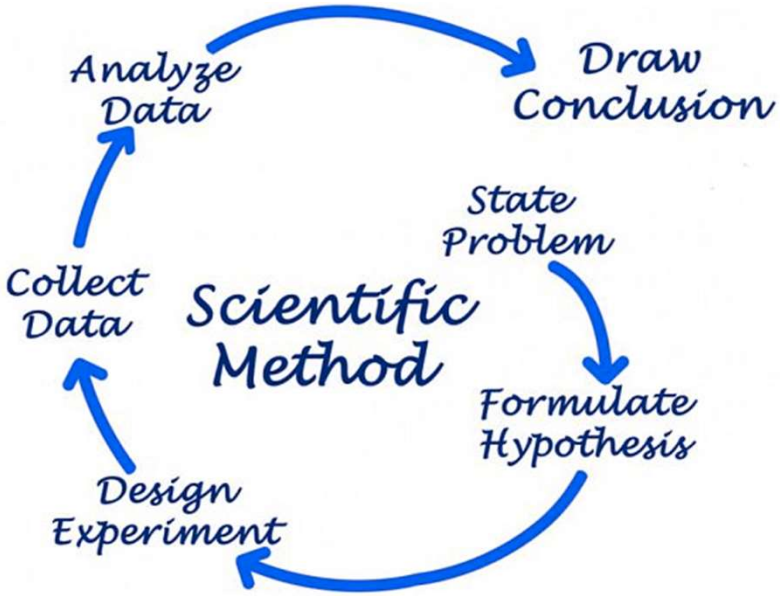

O que é Ciência de Dados

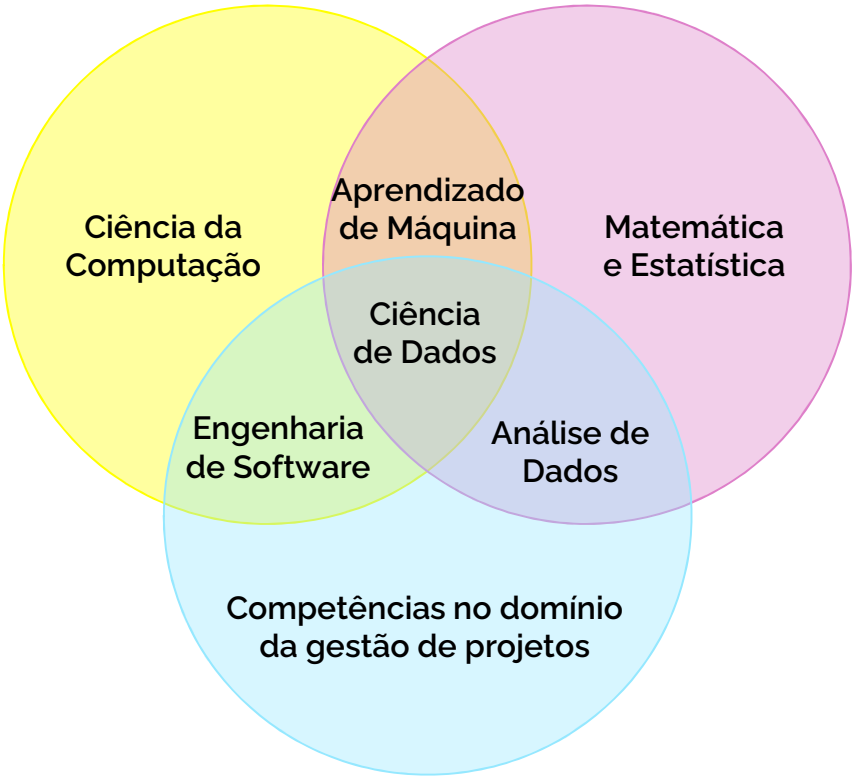

Tarefas

- Aprendizado supervisionado
- Aprendizado não-supervisionado
- Aprendizado por reforço

USP ICMC USP SÃO CARLOS CeMEAI CEPID - Centro de Ciências Matemáticas Aplicadas à Indústria

Aprendizado Supervisionado

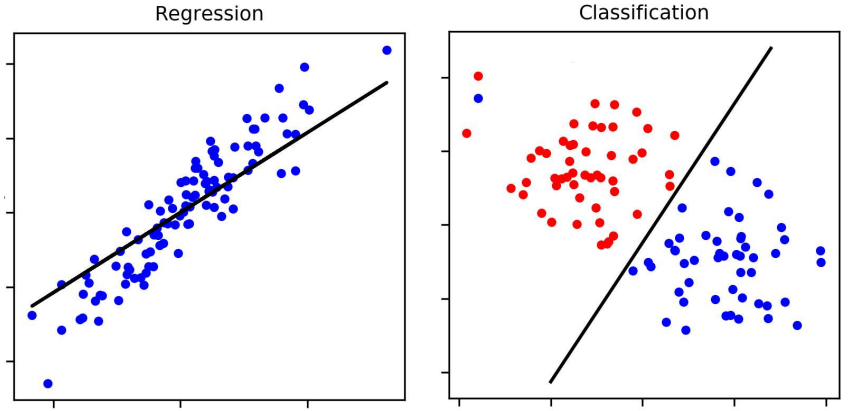

Como os computadores aprendem

Gato

Cachorro

Como os computadores aprendem

Gato

Cachorro

Como os computadores aprendem

Gato

Gato

Como os computadores aprendem

Gato

Cachorro

Como os computadores aprendem

Gato

👍

Cachorro

👍

Como os computadores aprendem

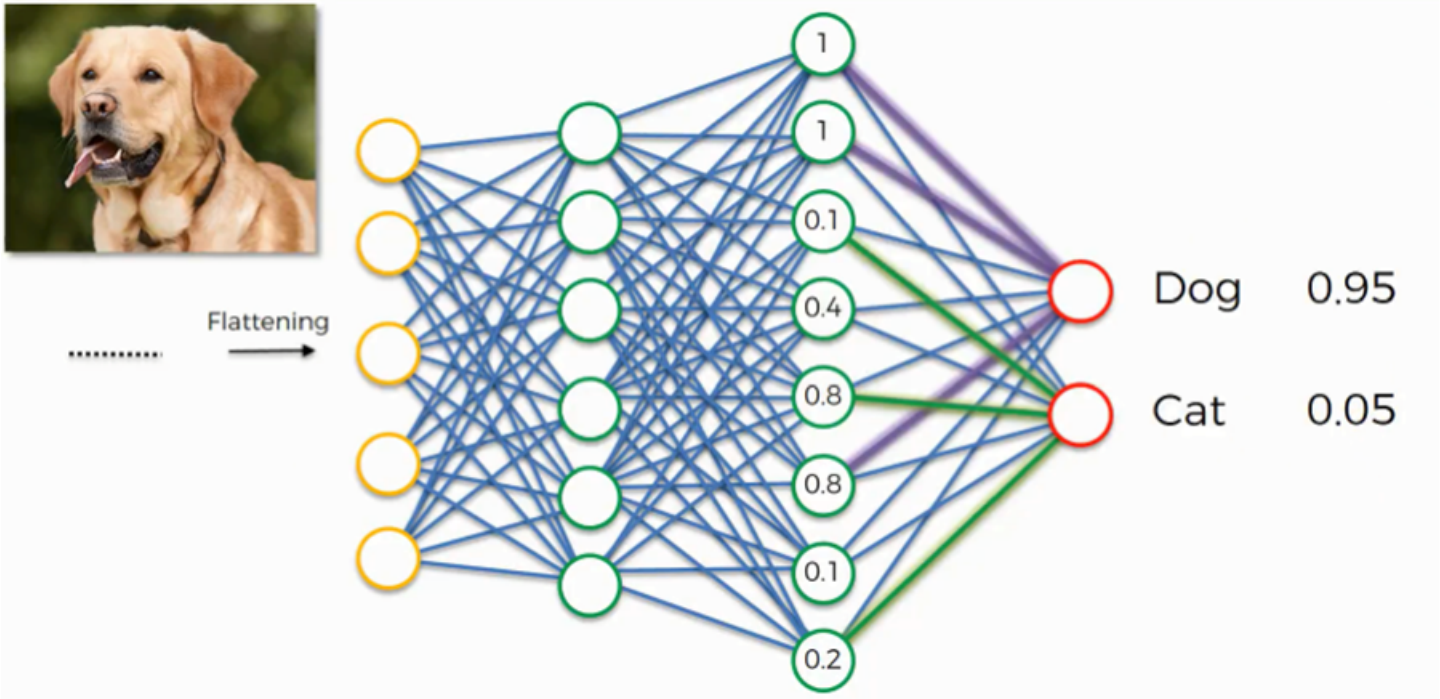

Aprendizado supervisionado

Modelos preditivos: função que, dado um conjunto de exemplos rotulados, constrói um estimador.

$$y = f(X, \theta) + \epsilon$$

Classificação

- Rótulos nominais (conjunto discreto e não ordenado de valores)
  - Ex. {doente, saudável}, {bom pagador, mau pagador}, {iris setosa, iris versicolor, iris virginica}
- Estimador é chamado **classificador**.

Regressão

- Rótulos contínuos (conjunto infinito ordenado de valores)
  - Ex. peso, temperatura, vazão de água.
- Estimador é chamado **regressor**.

Estimadores podem ser vistos como funções.

Classificação

Definição formal: Dado um conjunto de observações:

$$D = \{\mathbf{X}, \mathbf{y}, i = 1,\ldots,N\}$$

- **f** representa uma função desconhecida (função objetivo).
- Essa função mapeia as entradas nas saídas correspondentes.
- O algoritmo preditivo aprende a aproximação, que permite estimar valores de **f** para novos valores de **X**.

$$y_i = f(X_i, \theta) + \epsilon_i$$

Classificação

$$y_i \in \{C_1, C_2, \ldots, C_n\}$$

Classificação

Classificação de documentos:

Sports
Science
News

Classificação

Identificação de Fake News

Classificação

Diagnóstico de doenças

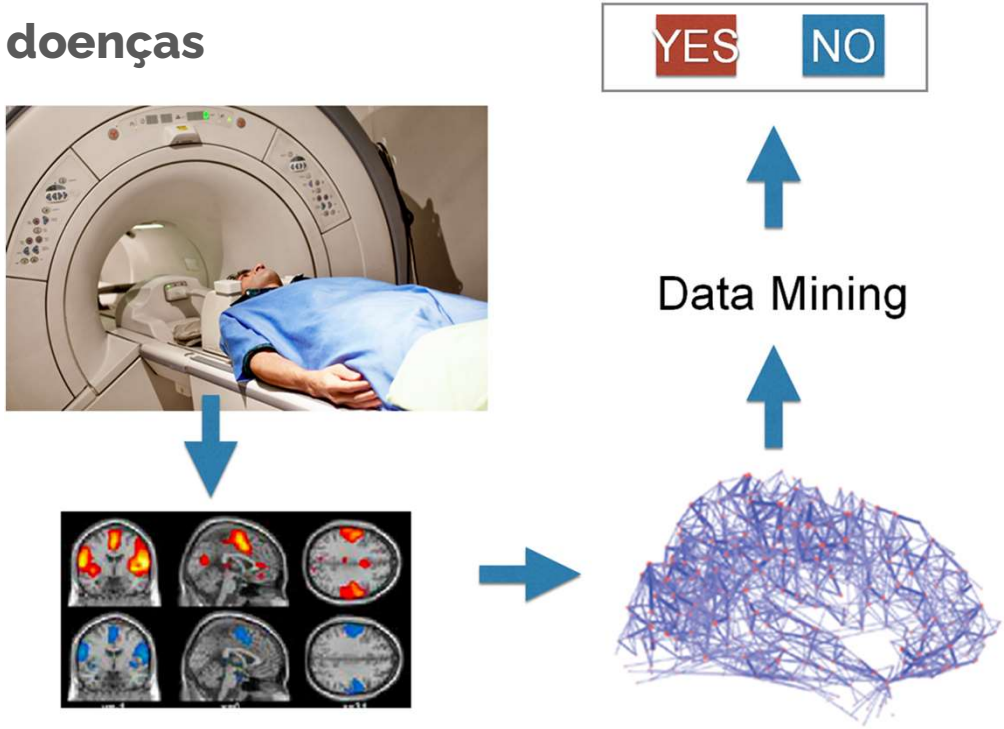

Classificação

Produtos Bancários

pixabay.com

Regressão

Definição formal: Dado um conjunto de observações:

$$D = \{\mathbf{X}, \mathbf{y}, i = 1,\ldots,N\}$$

- **f** representa uma função desconhecida (função objetivo).
- Essa função mapeia as entradas nas saídas correspondentes.
- O algoritmo preditivo aprende a aproximação, que permite estimar valores de **f** para novos valores de **X**.

$$y_i = f(X_i, \theta) + \epsilon_i$$

Regressão

$$y_i \in \mathbb{R}$$

Regressão

Exemplo:

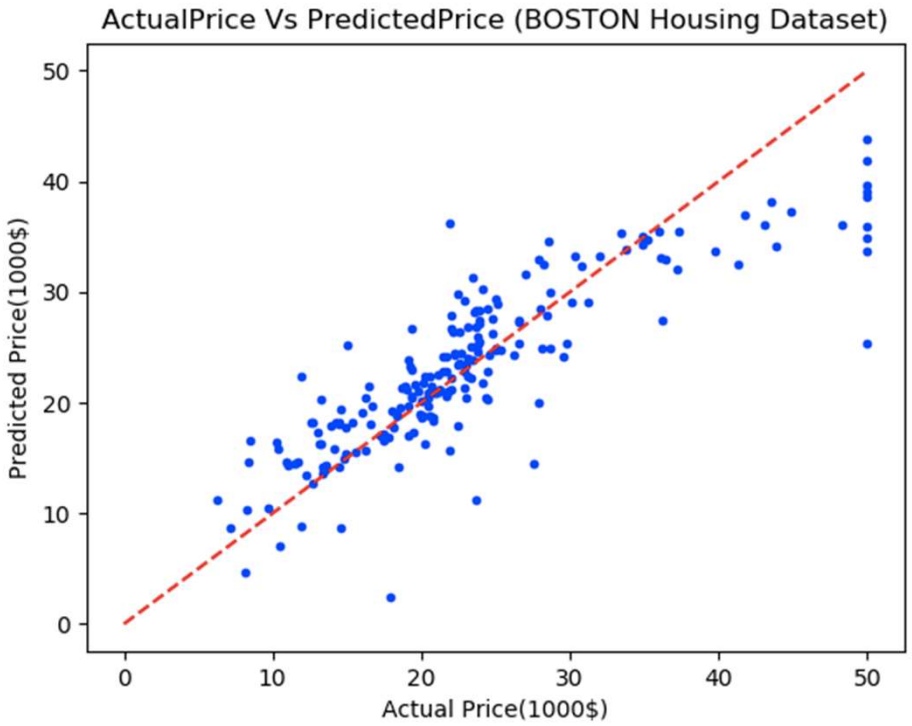

Regressão

Exemplo: Previsão de séries temporais

Regressão

Predição de secas:

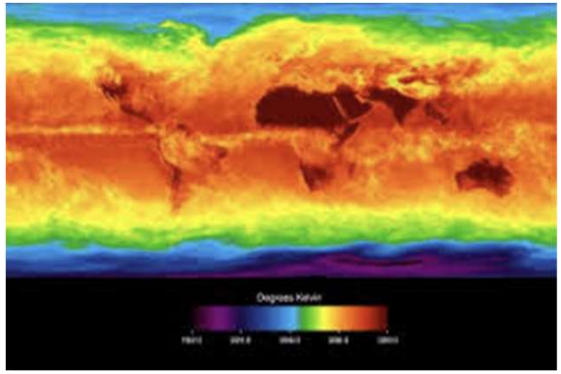

pixabay.com

Aprendizado supervisionado

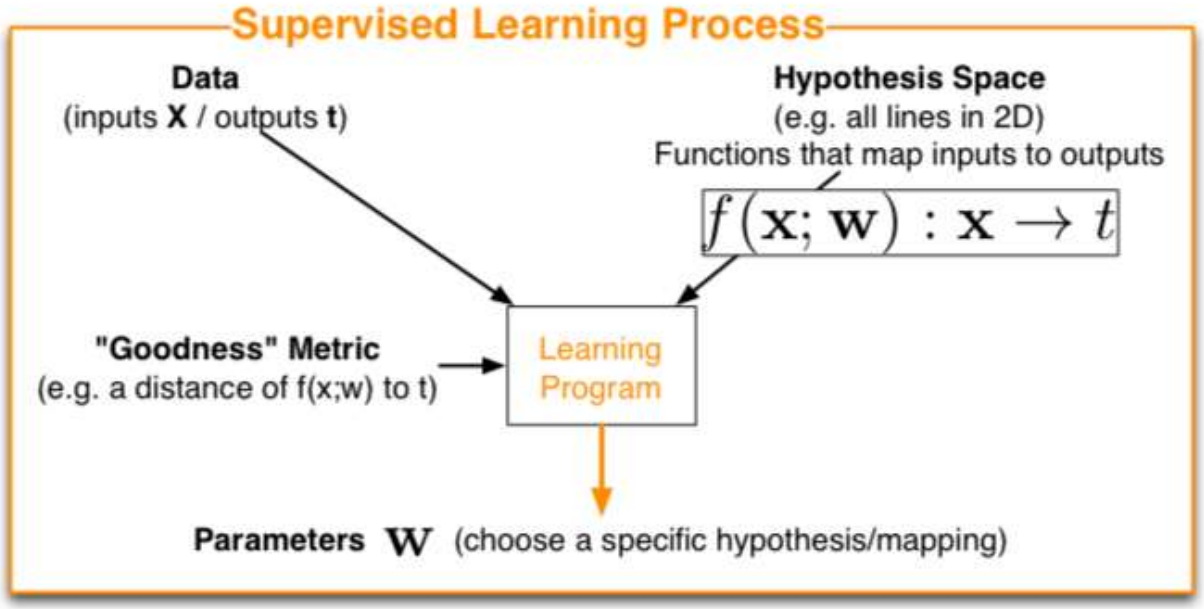

Aprendizado supervisionado

Tid	Refund	Marital Status	Taxable Income	Cheat (class)
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Refund	Marital Status	Taxable Income	Cheat
No	Single	75K	?
Yes	Married	50K	?
No	Married	150K	?
Yes	Divorced	90K	?
No	Single	40K	?
No	Married	80K	?

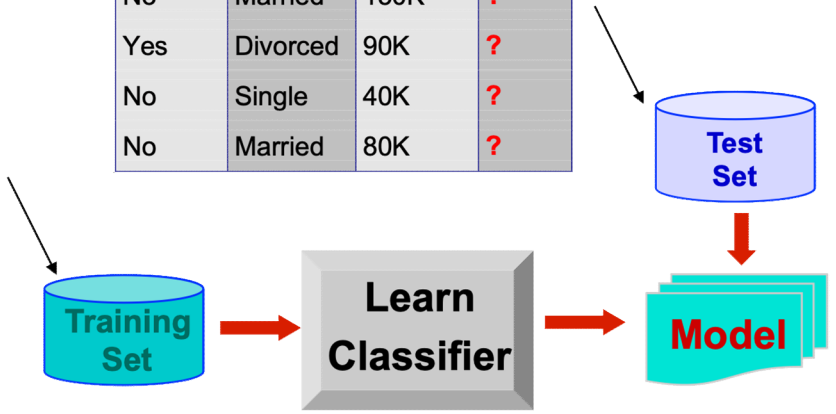

Aprendizado Não-supervisionado

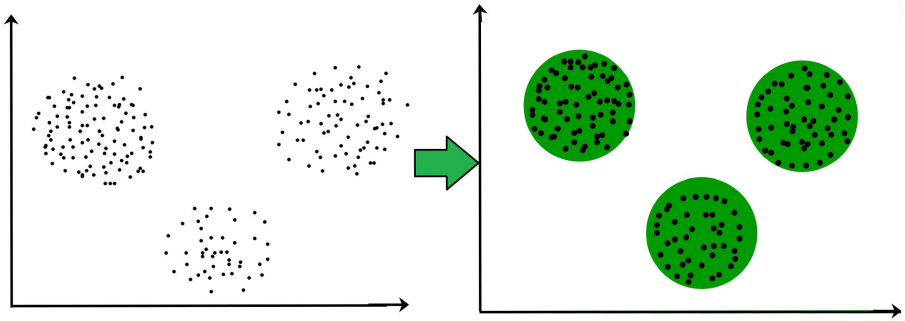

Agrupamento

Objetivo: Agrupar as observações de forma que a similaridade entre objetos no mesmo grupo seja máxima e a entre grupos seja mínima.

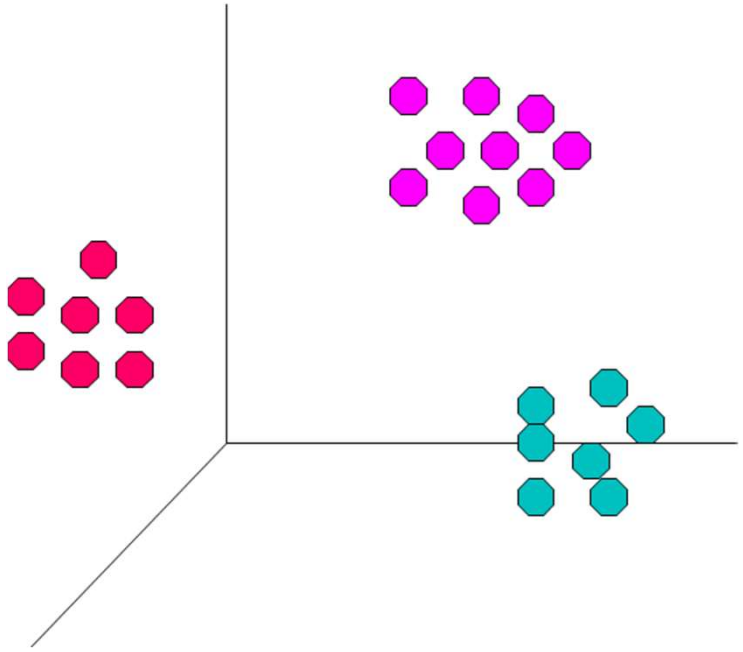

Agrupamento

Exemplo:

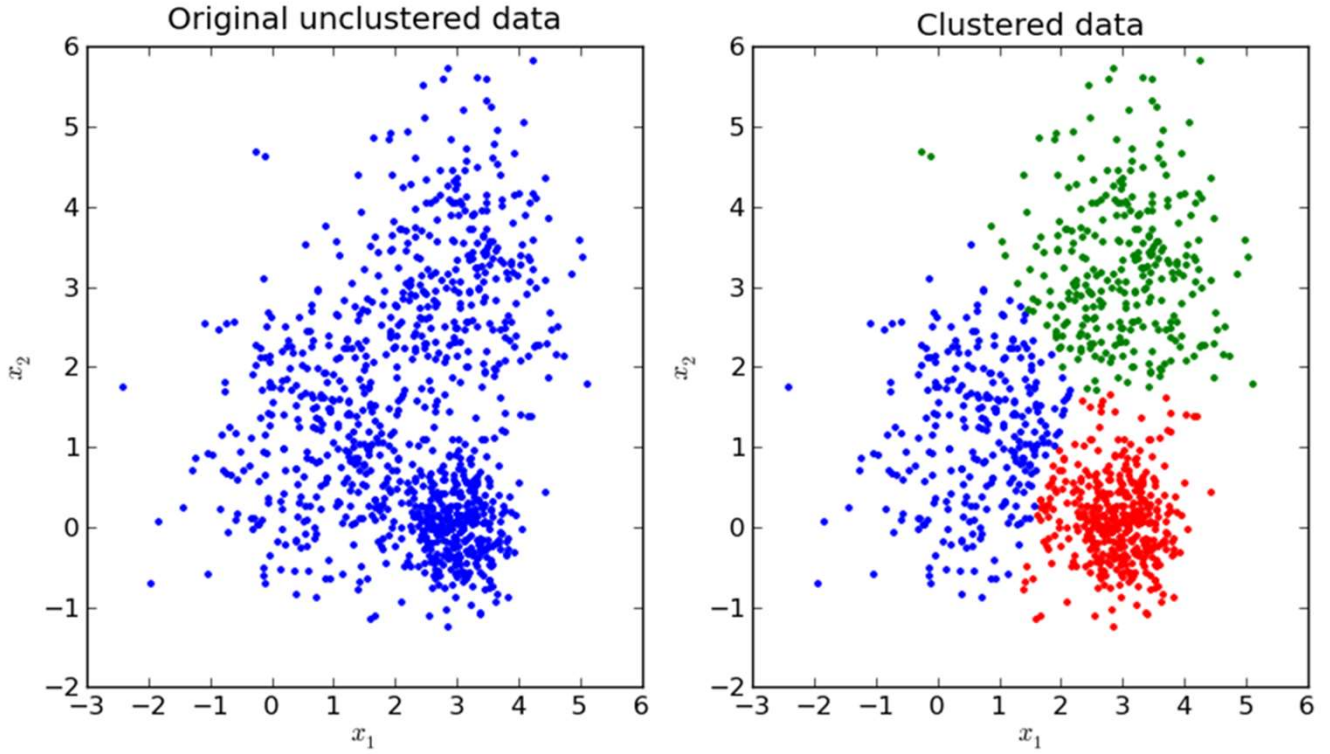

Agrupamento

Agrupar imagens similares:

Regras de associação

Dado um conjunto de transações, onde cada uma contém um número de itens de uma dada coleção,
produzir regras de dependência para predizer um item baseado na ocorrência de outros itens.

ID	Itens
1	Pão, Café, Leite
2	Cerveja, Pão
3	Cerveja, Café, Fralda, Leite
4	Cerveja, Pão, Fralda, Leite
5	Fralda, Leite, Café

Regras Descobertas:

{Leite} -> {Café}
{Fralda, Leite} -> {Cerveja}

Regras de Associação

Recomendação

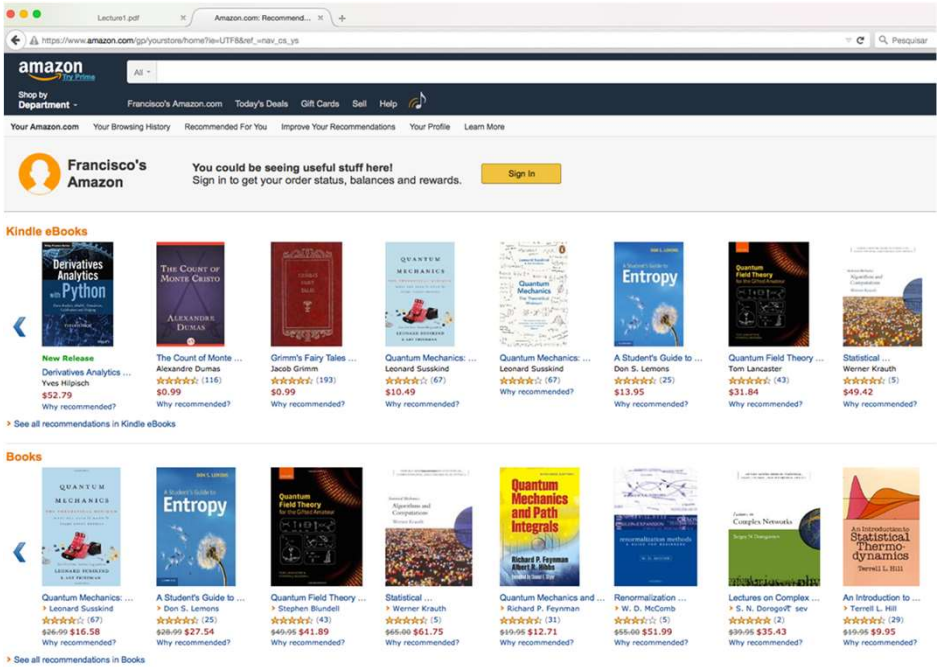

Problemas em Ciência de Dados

Recomendação

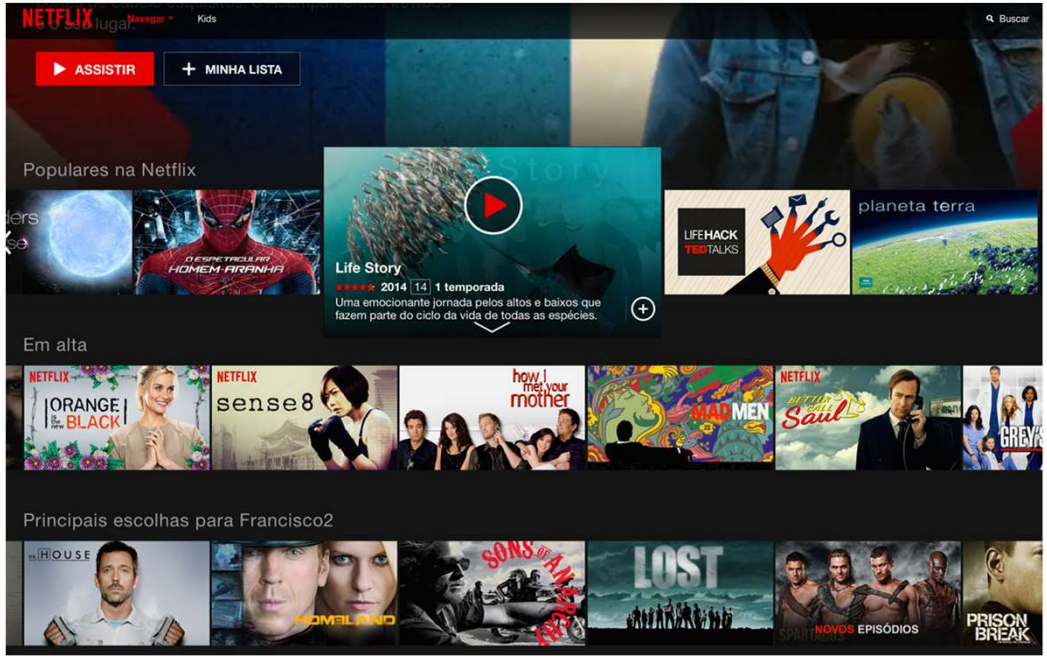

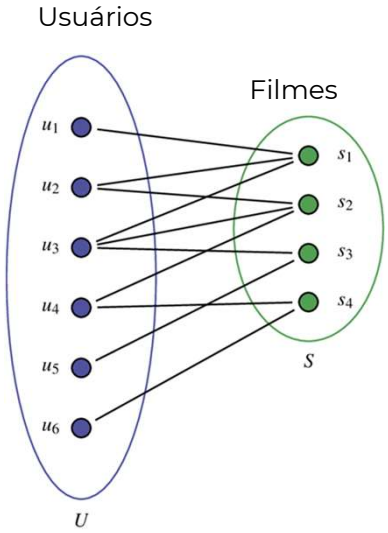

Detecção de outliers

Os outliers são dados que se diferenciam drasticamente de todos os outros, são pontos fora da curva.

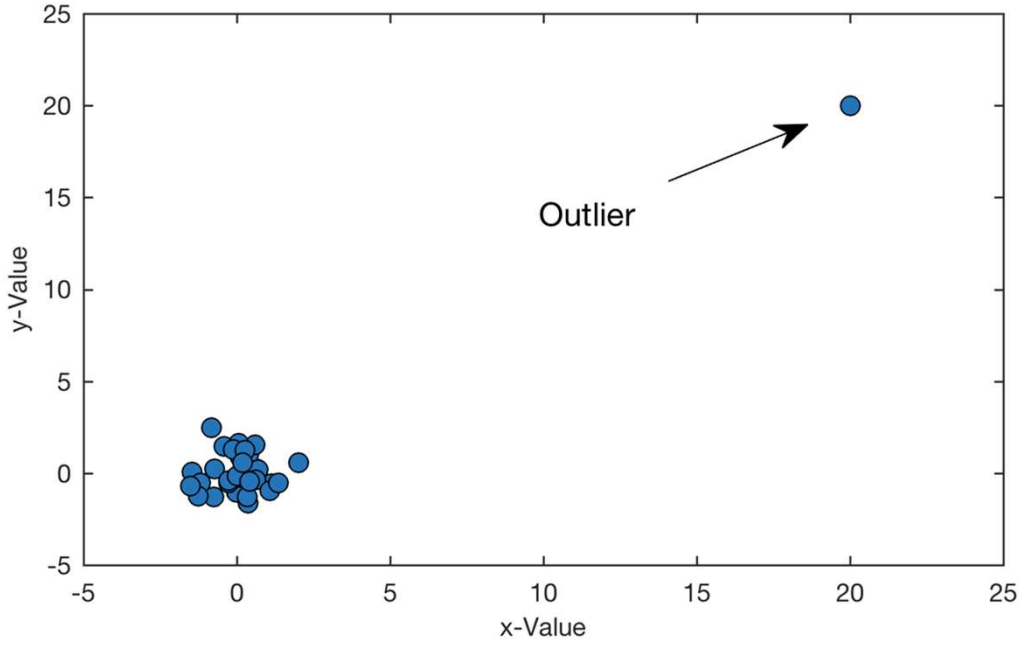

Detecção de Outliers

Operações Bancárias:

pixabay.com

Detecção de Outliers

Detecção de Fraudes:

pixabay.com

Outros tipos de aprendizado

- Aprendizado semi-supervisionado
- Aprendizado por reforço
- Auto-aprendizado

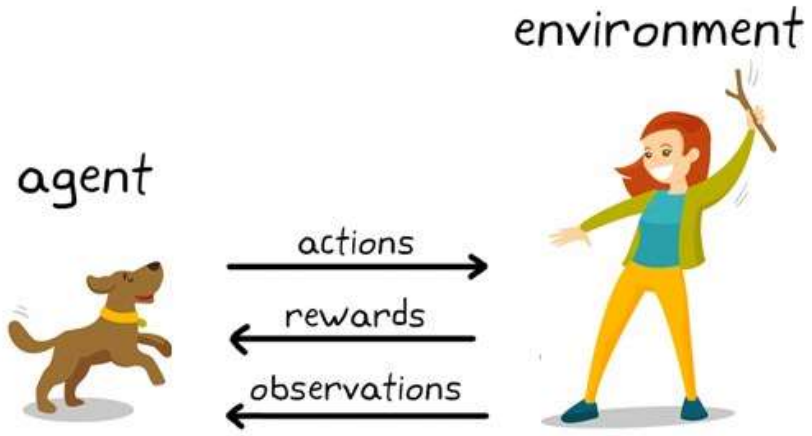

Problemas em Ciência de Dados

E-commerce
- Identificação de clientes
- Recomendação de produtos
- Análise de avaliações de produtos

Bancos
- Detecção de fraudes
- Modelagem de risco de crédito
- Mercado futuro

Medicina
- Análise de dados médicos
- Descoberta de novas drogas
- Bioinformática

Transporte
- Carros autônomos
- Sistema de monitoramento
- Segurança

Finanças
- Segmentação de usuários
- Decisões estratégicas
- Análise de risco

Agricultura
- Uso de pesticidas
- Previsão das safras
- Planejamento de lavouras

Ciência de Dados

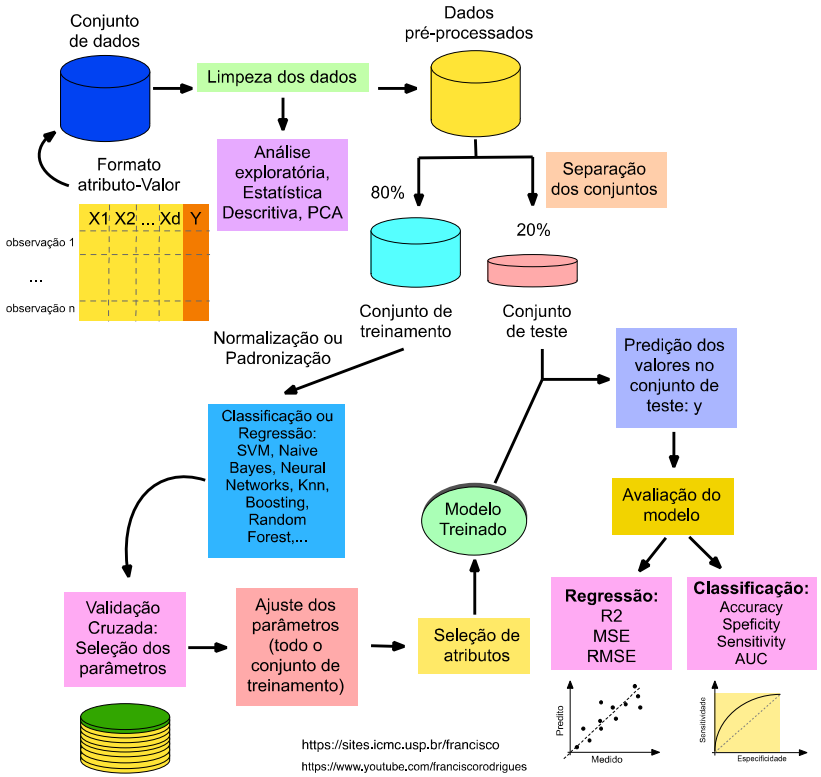

Agrupamento de dados

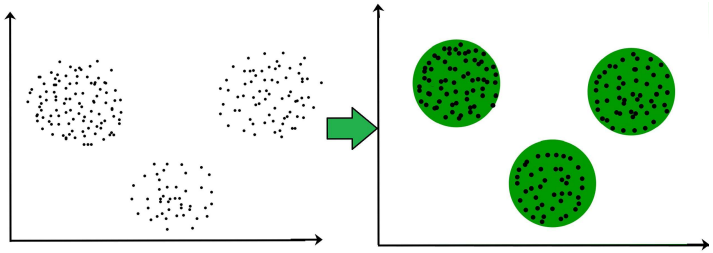

Data storytelling

Bibliotecas importantes

https://towardsdatascience.com/top-10-python-libraries-for-data-science-cd82294ec266

Sumário

- O que é Ciência de Dados
- Problemas e Soluções em Ciência de Dados

Leitura Complementar

- **A Brief Introduction to Machine Learning for Engineers**, Osvaldo Simeone
  https://arxiv.org/abs/1709.02840